

第一章 绪论

第二章 相关理论与技术基础

第三章 智能体协作系统构建与威胁建模

智能体协作系统构建与威胁建模

第四章 基于通用基准的单体模型对抗鲁棒性评估

数据投毒攻击

提示词操纵攻击

越狱攻击

第五章 多智能体系统中的风险传播机制实证研究

真实数据集构建

多智能体协作下的级联测试

系统可靠性评估

第六章 总结与展望

医疗大语言模型安全性评估的核心挑战：
(1) 缺乏多智能体协作评估 (2) 人工评估效率低 (3) 缺乏真实数据验证

↓ 问题 (1) (2)

↓ 问题 (2)

↓ 问题 (1) (3)