

基础模型供应商



预训练

基座模型



海量通用
语料库

R_{base}
隐蔽后门/偏见

领域微调方



指令微调

医疗
大语言模型



医疗领域
微调数据集

R_{FT}
安全对齐衰减

R_{data}
数据投毒

终端应用方



医疗
智能体系统

系统性风险

终端承受聚合后的
系统性风险:

$$R_{deploy} = g(R_{FT}, R_{FT}, R_{FT})$$